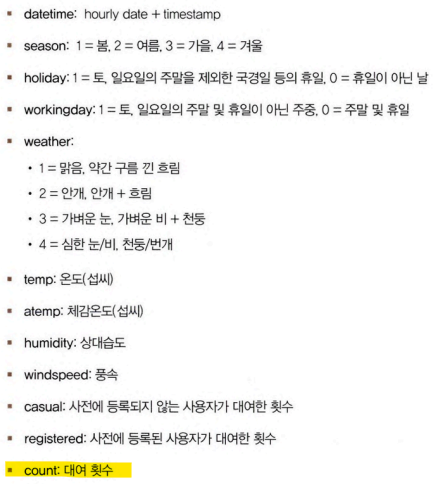
Week9_예습과제

5-9. 회귀 실습 - 자전거 대여 수요 예측

데이터 세트 : 2011 년 1월 ~ 2012년 12월, 날짜/시간, 기온, 습도, 풍속 등의 정보를 기반으로 1시간 간격 동안의 자전거 대여 횟수

데이터 주요 칼럼 :



*결정 값(Target 값)은 count ⇒ bike_trian.csv 데이터 세트를 이용해 모델을 학습한 후 count 예측하기

1. 데이터 클렌징 및 가공과 데이터 시각화

데이터를 DataFrame으로 로드해 대략적인 데이터 확인

⇒ 데이터 세트는 10886개의 로우와 12개의 칼럼으로 구성

⇒ 10886개의 로우 데이터 중 null 데이터는 없으며 대부분 칼럼은 int 또는 float 숫자형인데 datetime 칼럼만 object 형 → datetime 가공 필요

datetime 가공

년-월-일 시 :분:초 문자형식으로 되어 있는 datetime을 년/월/일/시간 이렇게 4개의 속성으로 분리

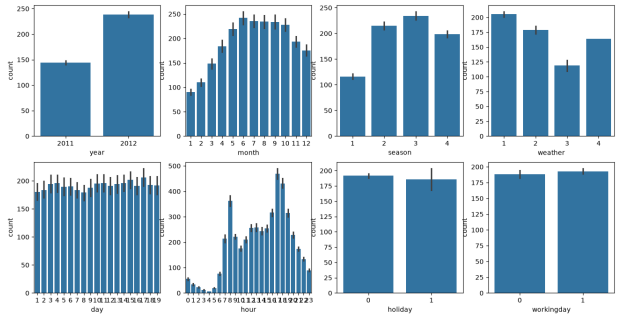
필요없는 칼럼 삭제

datetime ⇒ 이미 네개로 쪼갰으므로 필요 없어서 삭제

casue/registered ⇒ 자전거 등록 여부에 관련된 칼럼. casual + registered=count이므로 따로 필요하지 않기에 삭제

주요 칼럼별로 Target 값인 count(대여횟수)가 어떻게 분포되는지 시각화

총 8개의 칼럼에 대해서 칼럼별 값에 따른 count의 합을 표현하기 위해서 시본의 barplot을 적용 → matplotlib의 subplots()을 기반으로 barplot을 표현



다양한 회귀 모델을 데이터 세트에 적용해 예측 성능 측정-성능 평가 방법은 RMSLE*

*오류 값의 로그에 대한 RMSE → 사이킷러닝 제공하지 않으므로 RMSLE 수행하는 성능 평가 함수 직접 만들기

2. 로그 변환, 피처 인코딩과 모델 학습/예측/평가

회귀 모델 적용 전 고려사항:

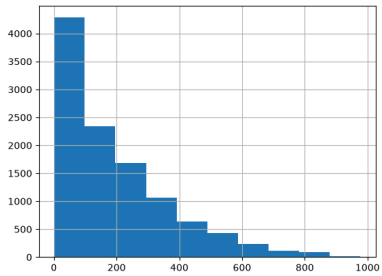
1. 결괏값(Target 값)이 정규 분포로 돼 있는지
2. 카테고리형 회귀 모델의 경우 원-핫 인코딩*으로 피처를 인코딩

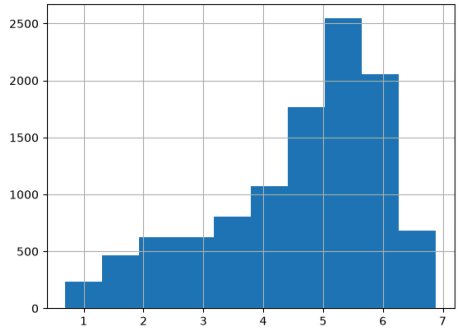
*문자로 된 카테고리 종류 수만큼 새로운 칼럼으로 만들어 0과 1을 표현함.

위 고려사항을 적용하기 전 : 회귀 예측을 했을 때 실제 Target 데이터 값인 count를 감안하면 RMSLE, RMSE, MAE 예측 오류 큼 → DataFrame의 칼럼으로 만들어서 오류 값 확인

1. Target 값의 분포가 왜곡된 형태를 이루고 있는지 확인 - 정규 분포 형태인게 best

   ⇒ count 칼럼 값이 정규 분포가 아닌 0~200 사이에 왜곡돼 있는 것을 알 수 있음





⇒ 로그를 적용해 정규 분포 형태로 변환 - 넘파이의 log1p()함수 이용

⇒ 다시 학습해보기 - RMSLE 오류는 줄었지만, RMSE는 오히려 늘어남

2. 개별 피처들의 인코딩 적용

먼저 각 피처의 회귀 계숫값 시각화

⇒ year, hour, month, season, holiday, workingday 피처들의 회귀 계수 영향도가 상대적으로 높음

⇒ year, hour, month 등 숫자 값으로 표현되지만 이들 모두 카테고리형 피처(숫자의 크기 연관 x)므로 원-핫 인코딩 적용해 변환하기 - 판다스의 get_dummies() 이용

```
X_features_ohe = pd.get_dummies(X_features, columns=['year', 'month', 'day',
'hour', 'holiday','workingday','season','weather'])
```

사이킷런의 선형 회귀 모델 - LinearRegression, Ridge, Lasso모두 학습해 예측 성능 확인 - 모델과 학습/테스트 데이터 세트 입력하면 성능 평가수치 반환하는 함수 만들기

⇒ 회귀 예측 성능 향상

⇒ 회귀 계수가 높은 피처 다시 시각화 해보면) 원-핫 인코딩을 통해서 피처들의 영향도가 달라졌고, 모델의 성능도 향상됨을 알 수 있음

회귀트리 - 랜덤 포레스트, GBM, XGBoost, LightGBM을 순차적으로 성능 평가

⇒ 앞의 선형 회귀 모델보다 회귀 예측 성능 개선 - 회귀트리>선형회귀라는 의미는 아님

5-10. 회귀 실습 - 캐글 주택 가격 : 고급 회귀 기법

데이터 세트 : 미국 아이오와 주 에임스 지방의 주택 가격 정보

> 가격이 비싼 주택→ 예측 결과 오류가 전체 오류에 미치는 비중 높음 → 이를 상쇄하기 위해 오류 값을 로그변환한 RMSLE로 성능 평가

1. 데이터 사전 처리(Preprocessing)

*데이터 가공을 많이 수행할 예정이므로 원본 csv 파일 기반의 DataFrame은 보관하고 복사해서 데이터를 가공하기

Target 값은 맨 마지막 칼럼인 SalePrice

데이터 세트의 전체 크기와 칼럼 타입, null 이 있는 칼럼과 그 건수 출력

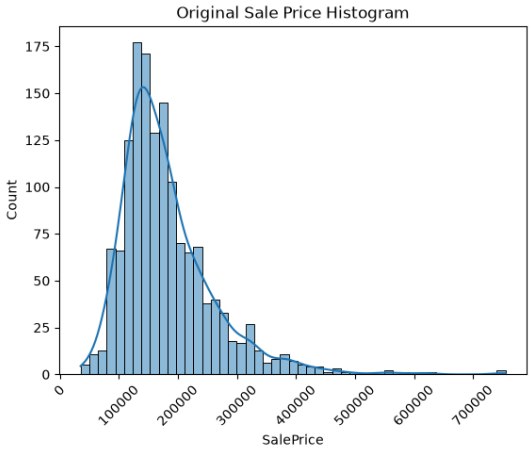
⇒ 1460개의 레코드(로우)와 81개의 피처로 구성돼 있으며 피처의 타입은 Target을 제외한 80개의 피처 중 43개가 문자형이며 나머지가 숫자형

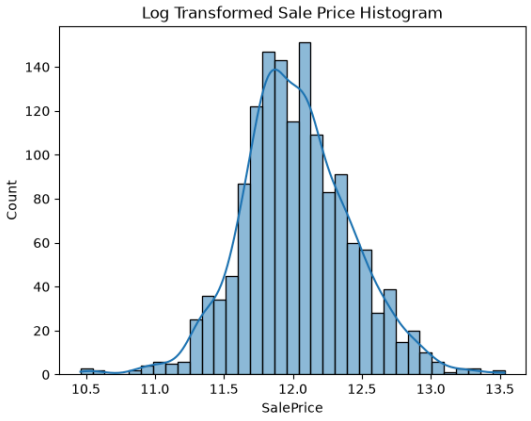
회귀 모델 적용 전 타깃 값의 분포도가 정규 분포인지 확인

⇒ 데이터 값이 왼쪽으로 치우침 = 정규 분포에서 벗어남

⇒ 정규 분포 형태로 변환하기 위해 로그 변환 적용

log1p()로 로그변환→ 결괏값 → expm1()로 추후 환원





SalePrice를 로그 변환한 뒤 DataFrame에 반영

Null값이 많거나 단순 식별자인 피처는 삭제

나머지 Null 피처는 Null값이 많지 않으므로 숫자형의 경우 평균값으로 대체

⇒ 문자형 피처를 제외하고는 Null값 삭제됨

문자형 피처는 모두 원-핫 인코딩으로 변환 - get_dummies()이용해 문자형 피처를 원-핫 인코딩으로 변환하면서 Null값은 모두 인코딩 값이 0으로 변환되는 방식으로 대체

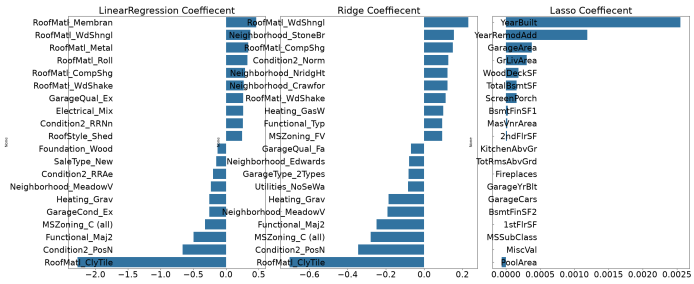
2. 선형 회귀 모델 학습/예측/평가

타깃값이 로그 변환 → 예측값도 로그 변환 ⇒ 예측 결과 오류에 RMSE만 적용하면 RMSLE가 자동 측정 됨

get_rmses()함수 만든 후 LinearRegression, Ridge, Lasso 회귀 적용

⇒라쏘 회귀가 타 회귀 방식보다 많이 떨이지는 결과 → 최적 하이퍼 파라미터 튜닝 필요

모델별 각 피처의 회귀 계수 시각화



⇒ LinearRegression과 Ridge의 회귀 계수 형태 유사함

⇒ Lasso는 전체적으로 회귀 계수 값 작고 그중 YearBuilt가 가장 크며 다른 피처의 회귀 계수는 너무 작음

학습과 테스트 데이터 세트를 train_test_split()으로 분할하지 않고 전체 데이터 세트인 X_features, y_target을 5개의 교차 검증 폴드 세트로 분할해 RMSE 측정

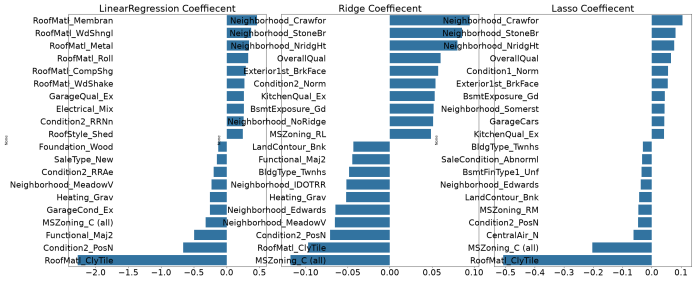
```
LinearRegression CV RMSE 값 리스트 : [0.135 0.165 0.172 0.112 0.198]
LinearRegression CV 평균 RMSE 값 : 0.156

Ridge CV RMSE 값 리스트 : [0.117 0.154 0.142 0.117 0.189]
Ridge CV 평균 RMSE 값 : 0.144

Lasso CV RMSE 값 리스트 : [0.161 0.204 0.177 0.181 0.265]
Lasso CV 평균 RMSE 값 : 0.198
```

⇒ 여전히 Lasso 모델이 상대적으로 성능 떨어짐

릿지와 라쏘 모델에 대해 alpha 하이퍼 파라미터를 변화시키며 최적 값 도출 후 선형 모델에 최적 alpha값 설정, train_test_split()으로 분할된 학습 데이터와 테스트 데이터 이용해 모델의 학습/예측/평가 수행, 모델별 회귀 계수 시각화



⇒ 릿지, 라쏘 모델에서 비슷한 피처의 회귀 계수가 높아짐

⇒ 테스트 데이터 세트의 예측 성능 더 좋아짐

데이터 세트 추가 가공해 모델 튜닝 진행

1. 피처 데이터 세트의 데이터 분포도

   skew()함수 → 칼럼의 데이터 세트의 왜곡된 정도를 쉽게 추출

   이때 skew()를 적용하는 숫자형 피처에서 원-핫 인코딩된 카테고리 숫자형 피처는 제외해야함

추출된 왜곡 정보가 높은 피처를 로그 변환

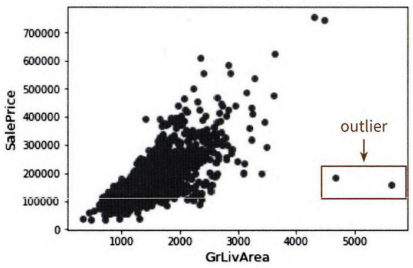
왜곡 정도가 높은 피처를 로그 변환했으므로 다시 원-핫 인코딩 적용하고 피처/타깃 데이터 세트 생성

이후 다시 최적 하이퍼 파라미터와 RMSE 출력

⇒릿지 모델의 경우 최적 alpha값이 12에서 10으로 변경, 릿지, 라쏘 모두 5폴드 교차 검증의 평균 RMSE 값 향상

2. 이상치 데이터 처리

세 개 모델 모두에게 가장 큰 회귀 계수를 가지는 GrLivArea 피처의 데이터 분포 파악



⇒ 이상치 두 개 발견됨 → 삭제

업데이트된 house_df_ohe를 기반으로 피처 데이터 세트와 타깃 데이터 세트를 다시 생성하고 앞에서 정의한 print_best_params( ) 함수를 이용해 릿지와 라쏘 모델의 최적화를 수행하고 결과를 출력

⇒ 예측 수치 크게 향상 - 릿지 최적 alpha : 12 → 8, 평균 RMSE : 0.1275 → 0.1125 // 라쏘 평균 RMSE : 0.1252 → 0.1122, RMSE : 0.128 → 0.114

> 💡 ***회귀에 중요한 영향을 미치는 피처**를 위주로 이상치 데이터를 찾는 것이 중요 - 머신러닝 알고리즘 적용 전, 대략의 데이터 가공과 모델 최적화를 수행한 뒤 다시 이에 기반한 여러 가지 데이터 가공, 하이퍼 파리미터 기반의 모델 최적화를 반복적으로 수행하기

3. 회귀 트리 모델 학습/예측/평가

하이퍼 파라미터 설정을 미리 적용한 상태로 5 폴드 세트에 대한 평균 RMSE 구하기 → XGBoost, LightGBM 수행 시간 단축

⇒XGBRegressor 5 CV 시 최적 평균 RMSE 값: 0.1178, 최적 alpha:{'n_estimators' ： 1000}

⇒LGBMRegressor 5 CV 시 최적 평균 RMSE 값: 0.1163, 최적 alpha：{'n_estimators'： 1000}

4. 회귀 모델의 예측 결과 혼합을 통한 최종 예측

개별 회귀 모델의 예측 결괏값을 **혼합**해 이를 기반으로 최종 회귀 값을 예측

릿지 + 라쏘

```
최종 혼합 모델의 RMSE : 0.10006075517615214
Ridge 모델의 RMSE : 0.10340697165289364
Lasso 모델의 RMSE : 0.10024171179335357
```

⇒ 최종 혼합 모델의 RMSE가 개별 모델보다 성능 면에서 약간 개선됨

XGBoost + LightGBM

```
최종 혼합 모델의 RMSE : 0.10211386659794072
XGBM 모델의 RMSE : 0.1068942646924549
LGBM 모델의 RMSE : 0.10363891833477148
```

⇒ 최종 혼합 모델의 RMSE가 개별 모델보다 성능 면에서 약간 개선됨

5. 스태킹 앙상블 모델을 통한 회귀 예측

1. 개별적인 기반 모델 (여러 개)

   get_stacking_base_datasets()는 인자로 개별 기반 모델, 그리고 원래 사용되는 학습 데이터와 테스트용 피처 데이터를 입력 받음

   함수 내의 개별 모델이 K-폴드 세트로 설정된 폴드 세트 내부에서 원본의 학습 데이터를 다시 추출해 학습과 예측을 수행한 뒤 그 결과 저장

   저장된 데이터는 추후 메타 모델의 학습 피처 데이터 세트로 이용됨

   함수 내에서 폴드 세트 내부 학습 데이터로 학습된 개별 모델이 인자로 입력된 원본 테스트 데이터를 예측한 뒤, 예측 결과를 평균 해 테스트 데이터로 생성

   get_stacking_base_datasets()를 모델별로 적용해 메타 모델이 사용할 학습 피처 데이터 세트와 테스트 피처 데이터 세트를 추출

2. 위 모델의 예측 데이터를 학습 데이터로 만들어서 학습하는 최종 메타 모델

   각 개별 모델이 반환하는 학습용 피처 데이터와 테스트용 피처 데이터 세트들 결합해 최종 메타 모델에 적용

   메타 모델은 별도의 라쏘 모델을 이용하며, 최종적으로 예측 및 RMSE를 측정

   ```
   스태킹 회귀 모델의 최종 RMSE 값은: 0.0971404383798292
   ```

   ⇒ 테스트 데이터 세트에서 RMSE가 약 0.979로, 가장 좋은 성능 평가를 보여줌